

보고 패턴에서 추출된 효과 크기로: 전문(Full-Text) LLM 마이닝은 스트레스 관련 뇌 변화의 방향은 복원하지만 그 크기는 부풀린다 — 380편 연구에 걸친 분석

강병수 (SYSOFT. 교신저자: shoo99@gmail.com), 2026

본 문서는 영문 원고 manuscript_v2_2.tex(제출본)의 한글 번역본입니다. 제출은 영문으로 진행되며, 본 한글본은 검토 용입니다. 모든 수치는 영문본과 동일합니다.

초록

배경. 동반 연구인 초록 수준 범위 고찰(9,585편, Research Square rs-9884522)은 만성 스트레스가 뇌를 어떻게 변화시키는지에 대한 **문헌 보고 패턴**(방향성 카운트)을 보고하였으며, 이것이 통합된(pooled) 효과 크기가 아님을 명시적으로 밝혔습니다. 반복되는 질문은, 전문(full text)에서 실제 수치 효과 크기를 추출했을 때 이러한 카운트 기반 패턴이 유지되는가입니다.

방법. 하이브리드 파이프라인을 적용했습니다 — PMC Open Access 전문에서 정규표현식으로 수치 후보를 사전 추출한 뒤, 각 후보를 (뇌 영역, 측정 지표, 방향, 값, 측정 유형) 레코드로 LLM 매핑(Qwen3.6-35B-A3B, llama.cpp, temperature 0의 35B Mixture-of-Experts 모델)하였습니다. 논문 수준 스트레스/질환 맥락 필터와 문장 수준 노이즈 필터(좌우 편측성 비교, 비율, 좌표/클러스터 통계, 보호 요인 및 과제 수행 상관 제거) 적용 후, 뇌 영역 × 측정 지표 부류별로 방향과 크기를 합성하였습니다. 추출이 문장 수준에서 이루어지므로 1차 분석 단위는 문장이 아닌 **연구(study)**입니다: 정확 이항 부호 검정 전에, 연구 × 영역 × 지표별로 다수결 방향 하나로 항목을 축약했습니다. 두 개의 맹검 자동 점검(어휘 기반 silver 규칙과 어려운 부분집합에 대한 독립 LLM 교차 점검)으로 방향 정확도를 추정했습니다. 이는 역분산(inverse-variance) 메타분석이 아닌 효과 크기 **합성(synthesis)**입니다: 연구별 표본 크기는 레코드의 약 6%에서만 복원 가능했습니다.

결과. 정제된 집합은 380편 연구의 효과 함유 문장 777개(7개 우선 영역의 항목 1,006개)로 구성되었습니다. 규칙 기반 silver 점검에서 어휘적으로 명확한 문장의 96%가 모델과 일치했고(불일치 대부분이 모델 오류가 아닌 silver 규칙 자체의 인공물이므로 이는 보수적 하한), 어려운 사례를 과표집한 50문장 부분집합에 대한 독립 LLM 교차 점검은 **90% 모델 간 일치**(상관-부호 항목은 82%)를 보였습니다. 5건의 불일치 문장을 원문과 대조해 직접 확인한 결과, 실제 증가가 구조적 감소로 잘못 라벨된 경우 — 즉 감소 우세 결론을 부풀릴 수 있는 경우 — 는 하나도 없었습니다. **연구 수준**에서 구조적 감소는 hippocampus에서 강건하게 유의했고(55 대 12편, 부호 $p=1\times 10^{-7}$), striatum 신호는 명목상 유의했으나 6편에만 근거했으며(6 대 0, $p=0.03$), amygdala는 연구 수준 집계에서 유의성을 잃었습니다(23 대 13, $p=0.13$) — 그 항목 수준 유의성은 연구 내 군집화의 인공물이었습니다. 기능적 지표는 어느 영역에서도 명확한 방향 신호를 보이지 않았습니다(amygdala 45 대 32편, $p=0.17$; hippocampus 18 대 14, $p=0.60$). 스트레스/중증도와 r형 상관관은 amygdala·hippocampus·ACC에서 $r\approx -0.30$ 에 모였습니다. 결정적으로, 이렇게 추출된 크기($r\approx -0.3 \approx \text{Cohen's } d\approx -0.68$)는 대응되는 개인-환자-데이터(IPD) 메타분석

(ENIGMA-PTSD hippocampus $d=-0.17$, amygdala $d=-0.11$)보다 **4-6배 큼**니다. 이는 출판·추출 가능한 문헌이 참 효과 크기를 체계적으로 과장함을 시사합니다. 따라서 전문 마이닝은 정준적 구조 감소 패턴의 **방향은 복원**하지만 그 **출판편향으로 부풀려진 크기를 재현**합니다.

결론. 카운트 기반 보고 패턴에서 추출된 효과 크기로 이동하면 스트레스 관련 구조 감소의 방향은 확인되지만, 컨소시엄 메타분석 대비 추출 크기가 수 배 부풀려져 있음이 드러납니다 — 대규모 LLM 마이닝이 출판편향을 벗어나는 것이 아니라 정량화할 수 있음을 보여줍니다. 우리는 파이프라인의 방향 신뢰도(어휘적으로 명확한 문장에서 96% silver 일치 — 보수적 하한 — 와 어려운 부분집합에서 90% 모델 간 일치, 모든 불일치를 원문과 직접 대조; 일치 점검 자체는 자동), 매핑 수율(약 43%), 그리고 표본 크기 부재를 투명하게 보고하여, 본 합성과 정식 메타분석 사이의 경계를 명확히 합니다. 포함된 모든 연구 목록은 보충 표 S1로 제공합니다.

키워드: 만성 스트레스; 뇌 구조; 효과 크기 합성; 전문 마이닝; LLM 추출; 출판편향; 효과 크기 부풀림; 메타분석 벤치마킹; hippocampus; amygdala

1. 서론

만성 스트레스 문헌은 소수의 정준적 진술이 지배합니다: 스트레스는 hippocampus 부피를 줄이고, amygdala 반응성을 높이며, 전전두 기능을 손상시킨다. 동반 연구[1]는 CPU 클러스터에서 3,970억 파라미터 LLM을 사용해 9,585편의 PubMed 초록에서 구조화된 방향 라벨을 추출함으로써, 그러한 진술이 **대규모에서 정량적으로** 유지되는지를 검증했습니다. 그 연구는 의도적으로 **보고 패턴**(문헌이 "감소" 대 "증가"를 얼마나 자주 말하는지)을 보고했고, 초록 수준 카운트가 통합 효과 크기가 아님을 강조했으며, 전문 정량 합성을 필수적 다음 단계로 지목했습니다.

본 논문이 그 단계를 밟습니다. 우리는 해당 연구들의 PMC Open Access 부분집합 결과(Results) 절에서 실제 수치 효과 크기(Cohen's d , Hedges' g , 상관 r , t/F 통계)를 추출하고, 각각을 그것이 기술하는 뇌 영역과 지표에 매핑한 뒤, 하나의 질문을 던집니다: **방향 주장 카운트에서 효과 크기 추출로 이동할 때, 초록 수준 패턴이 유지되는가?** 우리는 이 분야에서 가장 핵심적인 두 패턴 — 구조적 감소, 그리고 초록 수준 고찰이 "amygdala 증가" 논쟁을 해소한다고 주장한 구조-대-기능 해리 — 에 집중합니다.

우리는 이것이 정식 메타분석이 아닌 효과 크기 **합성**임을 분명히 합니다. 전문 문장은 역분산 가중에 필요한 선택적 표본 크기보다 효과 크기를 훨씬 자주 보고합니다. 따라서 우리는 연구 수준 방향 부호 검정과 크기 분포에 의존하고, 추출된 크기를 — 설계상 출판편향이 없는 — 이 분야 최대 규모 개인-환자-데이터(IPD) 메타분석과 대조하여, 독자가 방향이 복원되는지뿐 아니라 크기가 신뢰할 만한지까지 볼 수 있게 합니다. Hippocampus 위축 방향을 복원하는 것 자체는 파이프라인이 작동한다는 **개념 증명(proof of concept)**입니다. 본질적 기여는 그 후반부 — 동일한 LLM 규모 추출이 출판된 문헌의 **출판편향 부풀림**을, 추출된 크기를 편향 없는 벤치마크에 견주어 직접 측정 가능하게 만든다는 점 — 입니다. 따라서 가치는 알려진 패턴을 재확인하는 데 있는 것이 아니라, 수작업 고찰이 도달할 수 없는 규모에서 출판된 추정치와 편향 없는 추정치 사이의 간극을 정량화하는 데 있습니다.

2. 방법

2.1 코퍼스 및 전문 검색

9,585편 초록 코퍼스[1]에서 출발해, PMID를 PMC 식별자로 매핑하고 가용한 PMC Open Access 전문 XML(4,353편)을 검색했습니다. 각 논문의 결과 절(없으면 전체 본문)을 JATS XML에서 파싱했습니다.

2.2 정규표현식 사전 추출 (CPU, LLM 미사용)

각 결과 절을 문장으로 분리하고, 정제된 정규표현식으로 수치 효과 크기 후보($d, g, r, \beta, t(\cdot), F(\cdot), \eta^2$), 신뢰구간, p 값, 표본 크기($n=\cdot$), 뇌 영역 언급을 표시했습니다. 효과 크기 후보를 하나 이상 포함한 문장을 보유하여 LLM 매핑 후보 풀을 만들었습니다. 이 단계는 결정론적이고 재현 가능합니다(fulltext_hybrid_extract.py).

2.3 LLM 관계 인식 매핑

각 후보 문장을 CPU 클러스터의 35B MoE 모델(Qwen3.6-35B-A3B, llama.cpp, temperature=0)에 보내, 각 수치가 **스트레스 또는 스트레스 관련 질환과의 관계에서** 뇌 영역 지표의 변화를 정량화하는 경우(환자 대 대조군, 스트레스 대 비스트레스, 또는 스트레스/중증도 측정과의 상관)에 한해 {brain_region, metric, direction, value, measure_type}으로 매핑한 JSON 배열을 반환하도록 프롬프트했습니다. 프롬프트는 회귀 예측변수(연령, 성별, 교육, 약물), 과제 수행 상관, 스캐너/좌표 수치, 보호 요인 효과를 거부하고, 해당 없으면 빈 배열을 내도록 명시적으로 지시했습니다. 출력을 작게 유지하면(<512 토큰) 긴 출력에서 관찰된 양자화 관련 JSON 실패를 피할 수 있습니다. 우리는 동반 연구[1]의 초록 수준 추출에 쓰인 397B 모델 대신 의도적으로 소형 35B MoE 모델을 사용했습니다: 전문 과제는 사전 필터된 단일 문장에 대해 엄격히 제약된 출력 스키마로 작동하므로, temperature 0에서 소형 모델로 충분하면서 CPU 전용 클러스터에서 처리 가능했습니다. 정확한 프롬프트는 부록 A에 그대로 재현합니다.

2.4 2단계 노이즈 필터링

논문 수준 필터는 코퍼스 맥락이 스트레스/질환 관련인 연구로 매핑을 제한했습니다. 이어지는 **문장 수준** 필터(합성 시 적용)는 모델이 간혹 잘못 매핑한 잔여 노이즈 부류 — 좌우 편측성 비교, 부피 비율, MNI 좌표/클러스터 크기/TFCE 통계가 지배하는 문장, 보호 요인 문장, 인지 과제 수행 상관 — 를 제거했습니다. 투명성을 위해 필터 전후 결과를 모두 보고합니다.

2.5 합성 (메타분석 아님)

각 (영역, 지표 부류)에 대해 감소/증가/무변화 카운트를 집계했습니다. 추출이 문장 수준이고 단일 연구가 여러 항목을 기여할 수 있으므로, **1차 분석 단위는 문장이 아닌 연구**입니다: 각 연구 $\times$ 영역 $\times$ 지표 내에서 다수결(동률 제외)로 단일 방향을 배정하고, 연구 수준 방향에 대해 정확 양측 이항 부호 검정($H_0: p=0.5$)을 계산했습니다. 추가로 항목 수준 검정을 민감도 분석으로 보고하되, 연구 내 문장이 독립적이지 않으므로 항목 수준 p 값은 반보수적(anti-conservative)임을 명시합니다. 무변화/"차이 없음" 문장은 부호 검정에서 제외했으므로, 각 검정은 방향성 효과를 보고한 연구들 사이의 방향을 묻습니다. 출판편향 하에서 무변화 자체가 과소 보고되므로, 이는 방향 일관성 검정을 효과의 존재가 아니라 연구가 효과를 보고했다는 조건에 조건화합니다 — 카운트가 통합 효과 추정치가 아닌 또 하나의 이유입니다. 실제로 명시적 무변화는 추출 집합에서 드물었으므로(항목의 <2%; § 3.1), 연구 수준 제

외의 대부분은 무변화 범주가 아니라 연구 내 동률(연구 안에서 감소=증가)에서 발생합니다. 따라서 이 제외는 카운트보다 해석에 더 영향을 줍니다. r형 항목에 대해서는 크기 분포(중앙값, IQR)를 요약했습니다. 지표 부류는 구조적(volume, GMV, thickness, FA, density) 대 기능적(activation, connectivity, BOLD, ALFF)으로 구분했습니다. 사용 가능한 표본 크기가 레코드의 약 6%에만 나타났으므로 역분산 무선효과 통합은 시도하지 않았고, 출력을 방향+크기 합성으로 틀 짓고 크기를 외부 벤치마크(§ 3.7)에 견칩니다.

2.6 추출 검증

우리는 두 개의 상보적 자동 일치 점검과 소규모 수작업 판정 단계로 추출을 검증했습니다. 두 일치 점검은 **사람 라벨링을 포함하지 않으므로** 어느 것도 사람 기준(human gold standard)이 아니며, 유일한 사람 라벨 단계는 저자가 5건의 교차 점검 불일치를 직접 읽은 것임을 강조합니다(§ 2.6.1). 첫째, silver 점검: 모델 출력에 맹검인 상태에서 명시적 어휘 단서(reduced/smaller/lower → 감소; increased/greater/higher → 증가; 명확한 단서가 없는 문장은 제외)로 독립적 방향 라벨을 도출하고 모델의 방향 정확도와 감소/증가 혼동 행렬을 계산했습니다. 이 silver 라벨 자체가 표면 단서에서 유도되므로, 이미 어휘적으로 명확한 문장에서만 모델을 검증할 수 있으며, 방향성 합성에 가장 위험한 어려운 사례 — 부정(negation), "reduced deactivation", 상관-부호 매핑 — 에 대해서는 침묵합니다. 그래서 둘째, LLM 교차 점검(§ 2.6.1)을 추가했습니다.

2.6.1 어려운 부분집합에 대한 독립 LLM 교차 점검

원래 매핑에 맹검인 두 번째 LLM이, silver 점검이 제외한 사례 — 부정, 비활성화/저활성화, 상관(r형) 항목 — 를 의도적으로 과표집한 층화 50문장 표본의 축약 방향(감소/증가/무변화)을 재라벨했습니다(어휘적으로 명확한 몇 문장을 앵커로 포함). 상관 항목의 경우 재주석자는 상관 부호를, 상관 대상의 부호(예: cortisol/증상 중증도 대 회복탄력성/외상 후 경과 시간)를 읽어 지표 방향으로 매핑했습니다. 이것은 AI 대 AI 교차 점검이며 사람 기준이 아닙니다. 두 언어 모델이 체계적 오류를 공유할 수 있으므로, 이는 방향 인공물의 위험을 한정(bound)하지만 제거하지는 못합니다. 따라서 우리는 이 어려운 부분집합과 상관 항목에 대해 (정확도가 아닌) 모델 간 일치를 보고하고, 추가로 모든 불일치를 수작업 판정합니다: 저자가 원문 문장을 직접 읽어 불일치가 합성을 부풀리는 쪽으로 기우는지 검증합니다(§ 3.6). 이 5문장 판정이 파이프라인의 유일한 사람 라벨 단계이며, 일치 통계 자체는 자동입니다.

3. 결과

3.1 추출 수율 및 정제

스트레스 맥락 후보 문장 중 933개가 확신 있는 LLM 매핑을 산출했습니다(매핑 수율 $\approx 43\%$; 나머지는 "유의하지 않음" 진술과 비적격 수치가 지배하는 빈 배열). 분모가 정규표현식 후보 풀이고 효과 함유 문장의 참 집합을 독립적으로 알 수 없으므로, 재현율(recall) 대신 매핑 수율을 사용합니다. 문장 수준 노이즈 필터가 156문장(약 17%)을 제거하여, **380편 연구의 777문장, 7개 우선 영역의 효과 크기 항목 1,006개**(전 영역 매핑 항목 1,466개)의 정제 집합이 남았습니다. 1,006개 중 **769개가 ≥ 8 개 항목을 가진 셀에서 구조적 또는 기능적 방향을 지니며 표 1의 부호 검정에 들어갑니다**. 나머지 237개는 미분류 지표 유형 항목(218개; 예: 대사물질, 관류)이거나 하위 임계 영역 $\times$ 지표 셀(19개)입니다. 명시적 "무변화/차이 없음" 방향은 드물었으므로(LLM이 항목의 $<2\%$ 에서만 산출), 방향 카

운트는 무변화 범주에 의해 실질적으로 좌우되지 않습니다. 정제는 노이즈를 대체로 대칭적으로 제거했고 핵심 방향은 그대로 유지했습니다.




그림 1. 뇌 영역 × 지표 부류별 전문 효과 크기 방향 균형(정제 집합: 777문장, 380편 연구, 7개 우선 영역 1,006 항목). 막대는 감소 우세면 좌측, 증가 우세면 우측으로 뻗습니다(효과 크기 항목의 %; 음영이 둘을 구분). k = 셀에 항목을 기여한 연구 수로, 항목이 동물 또는 무변화로 귀결되는 연구를 포함합니다. 따라서 k는 표 1의 연구 수준 감소+증가 카운트(동물/무변화 제외)와 같거나 그보다 큼(예: amygdala 기능 k=87 대 45+32=77 비동물 연구). 구조 지표(파랑)는 모든 영역에서 감소 우세이며(hippocampus·striatum은 연구 수준에서 강건), 기능 지표(주황)는 유의한 방향 신호가 없습니다. **막대 길이는 항목 수준 비율**(한 연구가 여러 항목을 기여할 수 있어 가성반복으로 합의를 과대 표현 가능)이며, **모든 유의성 주장은 연구 수준**(연구당 다수결 방향 하나)에서 표 1의 부호 검정으로 이루어집니다. amygdala가 경계 사례입니다: 항목 수준 막대는 감소 경향이지만 연구 수준 검정은 비유의 (p=0.13)합니다.

표 1. 뇌 영역 × 지표 부류별 방향 합성(정제 전문 효과 크기). **연구 수준** 부호 검정(연구당 다수결 방향)이 1차 통계입니다. 항목 수준 카운트와 p값은 완전성을 위해 제시하나 연구 내 군집화로 인해 반보수적입니다. 부호 검정: 정확 양측 이항, 동물/무변화 제외.

영역	지표	연구 Dec	연구 Inc	연구 p	항목 Dec	항목 Inc	항목 p
Hippocampus	structural	55	12	1×10^{-7}	135	34	1.9×10^{-15}
Striatum	structural	6	0	0.03	14	0	1.2×10^{-4}

영역	지표	연구 Dec	연구 Inc	연구 p	항목 Dec	항목 Inc	항목 p
Amygdala	structural	23	13	0.13	62	24	5.1×10^{-5}
Amygdala	functional	32	45	0.17	96	114	0.24
Hippocampus	functional	14	18	0.60	38	39	1.0
Prefrontal cortex	functional	18	13	0.47	29	25	0.68
ACC	functional	9	7	0.80	15	10	0.42
Insula	functional	10	12	0.83	20	26	0.46
Striatum	functional	7	7	1.0	19	23	0.64
Thalamus	functional	3	5	0.73	4	9	0.27
Prefrontal cortex	structural	4	0	0.13	8	2	0.11
Thalamus	structural	4	1	0.38	9	4	0.27
Insula	structural	4	3	1.0	7	3	0.34

3.2 구조적 지표는 감소 우세

구조 지표 전반에서 모든 영역이 항목 수준에서 감소 우세로 기울었습니다(그림 1, 표 1). **연구 수준**(우리의 1차 단위)에서 구조적 감소는 hippocampus(55 대 12편; 부호 $p=1 \times 10^{-7}$)와 striatum(6 대 0; $p=0.03$)에서 유의했으나, amygdala에서는 유의하지 않았습니다(23 대 13; $p=0.13$): amygdala의 항목 수준 유의성($p=5.1 \times 10^{-5}$)은 연구 내 군집화에서 비롯되었고 연구당 단일 방향으로 축약하면 살아남지 못합니다. 전전두피질, insula, thalamus는 방향이 일관되었으나 검정력이 부족했습니다(모두 연구 수준 $p>0.1$). 따라서 강건하고 연구 수준에서 유의한 구조적 감소는 **hippocampus에 국한**됩니다. striatum 신호도 연구 수준에서 유의하나(기여한 6편 중 6편이 감소 보고, $p=0.03$) 가중하기엔 연구가 너무 적고, striatum 구조 감소는 정준적 스트레스 표현형의 일부가 아니므로 시사적인 것으로만 다룹니다. 이는 항목 수준 카운트만으로 시사되는 것보다 좁지만 더 방어 가능한 주장이며, 연구들 자신의 보고 효과 크기를 사용해 정준적 hippocampus 위축 서사와 일치합니다.

3.3 기능적 지표는 일관된 방향 신호가 없음

어떤 기능적 대조도 연구 수준에서 어느 방향으로도 유의에 도달하지 못했습니다(모두 $p>0.1$; 표 1). 스트레스 하에서 반응성 증가를 보인다고 흔히 기술되는 amygdala는 방향이 평탄했고 — 오히려 약하게 증가로 기울었습니다(증가 45 대 감소 32편, $p=0.17$). hippocampus도 마찬가지였습니다(증가 18 대 감소 14, $p=0.60$). 따라서 기능 신호는 일관된 증가가 아니라 방향적으로 이질적이라고 기술하는 것이 가장 적절합니다.

3.4 이중 해리가 아닌 구조-기능 비대칭

두 지표 부류를 나란히 놓으면(그림 1) 참된 이중 해리가 아니라 비대칭이 드러납니다. Hippocampus는 강한 구조적 감소(연구 수준 $p=1 \times 10^{-7}$)와 거의 균형 잡힌 기능 프로파일($p=0.60$)을 보이고, amygdala는 연구 수준에서 유의한 구조적 감소($p=0.13$)도, 유의한 기능적 증가($p=0.17$)도 보이지 않습니다. 진정한 구조-하강/기능-상승 해리

라면 기능 대조가 증가 방향에서 유의에 도달해야 하나, 어느 영역에서도 그렇지 않습니다. 따라서 정확한 진술은 구조는 감소하고(강건하게는 hippocampus에서만) 기능은 일관된 방향 신호를 갖지 않는다는 것입니다 — 여전히 유익하고, "amygdala 증가" 주장이 구조적 감소보다 약하다는 것과는 부합하지만, 대칭적 해리는 아닙니다.




그림 2. 영역별 r형 효과 크기 분포(정제 전문). 상자그림은 스트레스 노출/질환 중증도와의 상관 r; 점선은 r=0. amygdala, hippocampus, ACC는 $r \approx -0.3$ (중증도 음의 연관)에 모입니다.

3.5 원 연구가 보고한 그대로의 상관 크기

r형 항목 중 스트레스 노출 또는 질환 중증도와의 상관은 amygdala(중앙값 -0.32 , $n=113$), hippocampus(-0.32 , $n=90$), ACC(-0.30 , $n=28$)에서 $r \approx -0.30$ 에 모여, 보고된 그대로는 중증도 음의 연관을 나타냈습니다(그림 2) — 그러나 이 보고된 크기는 § 3.7에서 편향 없는 벤치마크 대비 약 4-6배 부풀려져 있음이 드러납니다. 전전두피질은 예외로, 양의 경향 중앙값($+0.27$, $n=32$)을 보여 이 문헌에서 전전두 상관의 이질적·과제 의존적 성격을 반영합니다.

3.6 추출 정확도

어휘 silver 규칙을 모든 변화형(감소/증가) 항목에 적용하니, 578개가 명확한 단일 극성 단서를 지녀 비교에 들어갔고, 모델의 매핑 방향이 silver 라벨과 556/578(**96.2%**)에서 일치했습니다. 22건의 불일치는 대칭적 모델 오류가 아니었습니다: 수작업 검토(22건을 비식별화하여 silver_disagreements_deidentified.csv에 기록; 원문은 PMC 경유) 결과, 14건은 단서 단어가 비교/대조군을 가리키거나("higher gray matter in the control group"), 다영역 문장에서 다른 영역을 가리키거나, 이중 부정("less negative connectivity")을 이룬 silver 라벨 인공물이었고 모델의 환자-방향 라벨이 실제로 옳았습니다. 또 다른 4건은 원문 자체가 모순된 문장(서술상 "greater"와 음의 보고 Cohen's d가 공존)으로 모델이 수치 부호를 따랐고, 단 4건만이 진정으로 모호했습니다. 따라서 96.2% 일치하는 방향 정확도의 보수적 하한이며, 원시 혼동 카운트(모델-감소 대 어휘-증가 19건, 그 역 3건)는 모델의 감소 편

항이 아니라 "대조군에서 더 큼" 구문의 빈도를 반영합니다. silver 라벨이 모델이 의존하는 동일 표면 단서에서 유도되므로, 이 점검은 어휘 단서가 있는 문장에만 적용됩니다.

50문장 어려운 사례 부분집합에 대한 LLM 교차 점검 (§ 2.6.1)에서, 두 번째 모델은 원래 매핑과 **90%**(45/50) 일치했습니다. 가장 어려운 층(상관-부호 항목)에서 **82%**(14/17), 부정 문장에서 93%(14/15)였습니다. 어느 모델도 정답(ground truth)이 아니므로 이를 정확도가 아닌 모델 간 일치로 보고합니다. 5건의 불일치는 표 2와 같이 분포합니다(행=원래 모델 라벨, 열=교차 점검 라벨): 원래 모델은 교차 점검이 동의하지 않은 4건에서 "감소"를 배정했고(2건→증가, 2건→무변화), 교차 점검이 표시한 1건의 감소를 놓쳤습니다(무변화→감소). 교차 점검을 오류 가능한 참조로 삼아 읽으면, 이 원시 패턴은 오히려 모델이 교차 점검보다 감소를 더 쉽게 배정하는 쪽으로 기울입니다. 즉 AI 대 AI 비교만으로는 헤드라인을 부풀릴 실패 양식인 경미한 감소 선호 경향을 배제하지 못합니다. 그래서 우리는 5개 원문 문장을 직접 읽었습니다 — 파이프라인의 유일한 사람 라벨 단계입니다. 4건의 모델-"감소" 중 2건은 본문 상 명백히 옳습니다. 하나는 첫 외상 노출 연령이 이룰수록 PTSD 환자의 선조체·대상회에서 [¹¹C]P943 5-HT_{1B} 수용체 결합(BP_ND)이 낮다고 보고된 경우이고[6], 다른 하나는 아동기 cortisol이 상대적으로 높은 일란성 쌍둥이가 amygdala-전전두 연결성이 낮음을 보인 경우입니다[7]. 둘 다 교차 점검이 부호를 잘못 읽은 고스트레스→저지표 관계입니다. 나머지 2건은 한 문장에 두 방향을 동시에 보고하는 진정으로 모호한 문장(putamen이 "hyperactivation... and... hypoactivation"; 치료 성과-연결성 상관)으로, 어느 것도 헤드라인 영역과 무관합니다. 유일한 무변화→감소 사례는 구조-부피 문장(PTSD 중증도 대 hippocampus $d=-0.22$ 및 amygdala $d=-0.12$, 비유의)으로, 모델이 둘 중 더 보수적으로 비유의 효과를 무변화로 매핑한 경우입니다. 결정적으로, 헤드라인 실패 양식 — 실제 증가가 구조적 감소로 추출되는 것 — 은 5건 중 **어디에도** 없었고, 유일한 구조 불일치에서는 모델이 감소를 과대가 아니라 과소 호출했습니다. 따라서 교차 점검은 hippocampus 신호에 감소 부풀림 추출 편향의 증거를 제공하지 않으며, 이 결론은 교차 점검 모델만이 아니라 **저자가 5개 원문 문장을 직접 읽은 데** 근거합니다. 더 큰 잔여 불확실성은 방향 부호 검정이 아니라 r형 크기 분포(상관-부호 일치 82%)에 있습니다. 두 일치 점검(silver, 교차 점검)은 자동이며, 불일치의 5문장 판정만 수작업으로 수행되었고, 더 큰 추출에 대한 전면적 사람 감사는 향후 과제로 남습니다.

표 2. 50문장 어려운 사례 부분집합에 대한 교차 점검 혼동 행렬 (§ 2.6.1). 행=원래 모델 라벨, 열=독립 교차 점검 라벨; 대각합(30+14+1=45)이 모델 간 일치입니다. 5개 비대각 불일치는 § 3.6에서 문장별로 검토합니다.

모델 ↓ / 교차 점검 →	decrease	increase	null	합계
decrease	30	2	2	34
increase	0	14	0	14
null	1	0	1	2
합계	31	16	3	50

3.7 추출된 크기 대 개인-환자-데이터 메가분석

크기 추정치를 외부 검증하기 위해, 설계상 출판편향이 없는 변연계 구조의 최대 규모 개인-환자-데이터(IPD) 메가분석과 비교했습니다. 중앙값 상관을 Cohen's d 로 변환하면($d=2r/\sqrt{1-r^2}$): hippocampus $r=-0.32 \rightarrow d \approx -0.68$; amygdala $r=-0.32 \rightarrow d \approx -0.68$; ACC $r=-0.30 \rightarrow d \approx -0.63$. 대응되는 IPD 추정치는 뚜렷이 더 작습

니다: ENIGMA-PTSD는 hippocampus $d=-0.17$, amygdala $d=-0.11$ (후자는 다중비교 보정에서 생존 못함)을 보고했고[2], ENIGMA-MDD는 hippocampus $d=-0.14$ (재발성 -0.17)을 보고했습니다[3]. 두 가지 단서가 이 비교를 날카롭게 합니다. 첫째, 추정 대상이 다릅니다: IPD 연구는 환자-대조군 집단 차이를 추정하지만, 우리 r형 항목의 상당 부분은 이환 표본 내 중증도 상관입니다. 이들은 상호 교환 불가하므로, 아래 비율은 보정된 편향 계수가 아니라 자릿수 수준의 불일치로 읽어야 합니다. 둘째, 가장 깔끔한 동종 벤치마크는 중증도 자체이며, 거기서 간극이 가장 큼니다: ENIGMA-MDD는 증상 중증도와 영역 부피 사이에 아무런 연관을 찾지 못했으나[3], 우리의 추출 중증도 상관은 $r \approx -0.3$ 에 모입니다 — 어떤 단일 배수로도 포착되지 않는 질적 불일치(무 대 중증도). 집단 차이 항목에 대해 우리의 추출 크기는 편향 없는 벤치마크를 약 4-5배(hippocampus, 어느 컨소시엄 추정치를 분모로 쓰느냐에 따라)에서 약 6배(amygdala)까지 초과합니다. 우리 파이프라인이 각 논문에서 보고된, 대개 유의한 효과를 우선적으로 복원하므로, 이 비율들은 오히려 참 보고 부풀림의 보수적 하한입니다. 따라서 우리 합성의 방향은 기준(gold standard)과 일치하지만, 그 크기는 출판 가능 문헌에서 크고 유의한 효과를 선택적으로 보고한 것을 반영합니다.

4. 논의

핵심 결과는 양면적입니다. 방향에서 전문 마이닝은 안심을 줍니다: hippocampus의 스트레스 관련 구조적 감소가 연구 수준 방향 유의성($p=1 \times 10^{-7}$)으로 복원되어, 우리 초록 수준 카운트와 컨소시엄 메타분석 모두와 일치합니다. 크기에서는 수정주의적입니다: 추출된 상관($r \approx -0.3 \approx d \approx -0.68$)이 편향 없는 메타분석 효과($d \approx -0.14 \sim -0.17$)를 4-6배 과장합니다. 따라서 초록 수준과 전문 카운트 사이의 일치는 문헌이 편향 없음을 입증하지 않습니다 — 둘 다 동일한 상류 출판편향을 물려받으며, 우리의 크기 비교가 그것을 가시화합니다. 따라서 본 연구의 기여는 단지 서사를 확인하는 것이 아니라, LLM 규모 마이닝이 출판된 추정치와 편향 없는 추정치 사이의 간극을 정량화할 수 있음을 보이는 데 있습니다.

이는 방법론적으로 중요하지만, 교훈은 깔끔한 검증의 반대입니다. 초록 수준 방향 카운팅이 저자들이 초록을 표현하는 방식의 인공물일 수 있다는 우려가 가능합니다. 전문 카운트가 같은 방향으로 떨어지는 것은 표현 인공물은 배제하지만, 무엇이 애초에 출판되느냐에 작용하는 — 초록과 결과 절이 똑같이 공유하는 — 출판 편향은 배제하지 못합니다. IPD 메타분석과의 비교(§ 3.7)가 이를 구체화합니다: 초록 수준과 전문 추정치 모두 편향 없는 벤치마크 대비 동일한 수 배 크기 부풀림을 지닙니다. 실질적 함의는, 출판된 텍스트의 LLM 규모 마이닝이 방향과 출판편향 간극 정량화에는 신뢰할 만한 도구이지만, 편향 없는 크기가 목표일 때 IPD 통합을 대체하지는 못한다는 것입니다. 두 번째 냉정한 관찰은, amygdala 구조적 감소(항목 수준에서는 유의하나 연구 수준에서는 아님)가 문장 수준 분석에서는 과대 주장되었을 것이라는 점입니다. 연구 수준 집계는 형식이 아니라 가성반복적 위양성에 대한 방어책입니다.

4.1 한계

우리는 틀 짓기에서 의도적으로 보수적입니다. 첫째, **이것은 통합 메타분석이 아닙니다**: 연구별 표본 크기가 레코드의 약 6%에서만 추출 가능해 역분산 가중이 불가하므로, 대신 방향 부호 검정과 크기 분포를 보고합니다. 둘째, **매핑 수율이 중증도입니다**(스트레스 맥락 후보 문장의 약 43%가 확신 있는 매핑을 산출). 미매핑 문장은 무변화 결과와 비적격 수치가 지배하지만 일부 참 효과를 놓치므로, 카운트는 하한입니다. 셋째, **가성반복**. 추출이 문장 수준이라 단일 연구가 여러 항목을 기여할 수 있어 소박한 부호 검정의 독립성 가정을 위반합니다. 우리는 연구를 1차 단

위로 삼아(연구 × 영역 × 지표당 다수결 방향; § 2.5) 이를 다루며, 항목 수준 카운트는 투명성을 위해서만 유지합니다. amygdala 결과는 이 구분이 형식이 아니라 실질임을 보여줍니다. 잔여 비독립성은 남으므로(연구들이 방법·집단·분야 수준 사전 신념을 공유), 연구 수준 유의성조차 역분산 통합과 동등하지 않습니다. 넷째, **표 세기(vote-counting)는 알려진 한계의 합성법입니다**: 효과 크기와 연구별 정밀도를 무시하며, 검정력이 부족한 구성 연구들에서는 연구 수가 늘수록 잘못된 결론에 수렴할 수 있습니다[4,5]. 우리 부호 검정은 통합 효과 추정이 아니라 출판된 기록에서의 방향 일관성 검정으로 읽어야 합니다. 다섯째, **크기는 출판과 유의성에 조건화됩니다**("승자의 저주"). § 3.7은 이를 IPD 메타분석 대비 4-6배 간극으로 정량화하며, 연구별 표본 크기 없이는 깔때기 도표나 trim-and-fill을 적용할 수 없으므로, 중앙값 r 은 편향 보정된 모집단 효과가 아니라 선택된 표본의 상향 치우친 요약입니다. 여섯째, **구성 개념 혼합**: 예측변수 "스트레스 노출/질환 중증도"는 구조와의 관계가 그럴듯하게 다른 이질적 구성 개념(만성 스트레스, PTSD, MDD, 초기 생애 역경, cortisol, 지각된 스트레스)을 모읍니다(예: ENIGMA-MDD는 중증도-부피 연관을 찾지 못함). 그림 2의 넓은 IQR이 이와 부합하며, 노출 유형별 층화 합성은 명백한 향후 과제입니다. 일곱째, 코퍼스는 특정 저널을 과대 대표하는 PMC Open Access 부분집합입니다. 여덟째, **우리 검증은 방향 정확도를 확립하지 정량적 정밀도를 확립하지 않습니다**: silver와 교차 점검 감사는 모두 추출 효과의 부호가 옳은지를 채점하며, 파이프라인이 각 r 또는 d 의 정확한 수치를 복원한다고 주장하지 않습니다. 잘못 파싱된 크기(예: 신뢰구간 경계를 점추정치로 읽음, 또는 편상관 대 영차 상관)는 방향 전용 점검으로 잡히지 않으므로, 그림 2의 크기 분포는 § 3.7에서 정량화한 출판편향 부풀림 위에 자체 잔여 추출 노이즈를 더한, 우리 파서가 복원한 보고된 값으로 읽어야 합니다. 추출 크기를 손으로 읽은 값과 대조하는 수치 감사는 명백한 향후 과제입니다. 이러한 경계가 바로 본 효과 크기 합성을, 우선 영역에 대한 연구별 효과/표본 크기의 수동 큐레이션을 요구하는 등록 메타분석과 구분하는 지점입니다.

4.2 결론

380편 연구에 걸친 전문 효과 크기 합성은 연구들 자신의 수치로 스트레스 관련 hippocampus 구조 감소의 방향을 복원하지만, 편향 없는 IPD 메타분석 대비 추출 크기가 4-6배 부풀려져 있음을 보입니다. 따라서 출판된 텍스트의 LLM 규모 마이닝은 방향과 분야의 출판편향 정량화에는 신뢰할 만한 도구이지만 — 그것을 벗어나는 도구는 아닙니다. 우리는 파이프라인의 방향 신뢰도를 난이도별로 정직하게 보고합니다(어휘적으로 명확한 문장에서 96% silver 일치 — 보수적 하한 — 와 부정·상관·부호 매핑을 강화한 어려운 부분집합에서 90% 모델 간 일치; 저자의 불일치 문장 읽기에서 감소 부풀림 오류는 발견되지 않음), 매핑 수율(약 43%), 표본 크기 부재도 함께 보고하여, 본 합성과 정식 메타분석 사이의 경계를 명시합니다.

데이터 및 코드 가용성

- 포함된 모든 연구의 완전한 목록(PMID, 제목, 저널, 연도, PMC ID): 보충 표 S1.
- 원 초록/전문: 보충 표 S1의 식별자를 통해 각 논문의 라이선스 하에 PubMed/PMC에서 조회 가능.
- 추출·합성 코드(fulltext_hybrid_extract.py, LLM 매핑 러너, 합성/부호 검정 스크립트), 정확한 LLM 프롬프트(부록 A), 비식별화된 LLM 매핑 효과 크기 레코드는 <https://github.com/shoo99/ai-drug-target> (디렉터리 paper3/)에 공개되어 있습니다.

동반 프리프린트

본 연구는 초록 수준 범위 고찰을 확장합니다: Kang B. (2026), Large-Scale Scoping Review of Chronic Stress-Induced Brain Changes via LLM-Powered Extraction of 9,585 Studies, Research Square, 10.21203/rs.3.rs-9884522/v1.

감사의 글

LLM 추출은 분산 CPU 클러스터(GPU 없음)에서 수행되었습니다. 원고 준비는 Claude(Anthropic)의 도움을 받았습니다. 저자가 모든 과학적 내용에 대한 전적인 책임을 집니다.

이해 상충

저자는 이해 상충이 없음을 선언합니다.

부록 A. LLM 추출 프롬프트 (그대로)

각 후보 문장은 채팅 템플릿 `<|im_start|>user ... <|im_end|><|im_start|>assistant`로 감싸고, 미리 닫힌 `<think></think>` 블록(no-think 모드)과 다음의 one-shot 예시 및 지시를 함께 제시했습니다:

Example 1 (map: stress->region effect) –

```
Sentence: "Patients with PTSD showed reduced hippocampal volume vs controls (Cohen's d=-0.45), and amygdala activation correlated with cortisol (r=0.38)."  
Output: [{"brain_region":"hippocampus","metric":"volume","direction":"decrease",  
"value":-0.45,"measure_type":"d"}, {"brain_region":"amygdala",  
"metric":"activation","direction":"positive_correlation","value":0.38,  
"measure_type":"r"}]
```

[the candidate sentence + its regex-detected numbers are inserted here]

This sentence is FROM A CHRONIC-STRESS / STRESS-DISORDER STUDY (PTSD, depression/MDD, early-life stress, trauma, high cortisol), so a brain-region group difference or change reported here IS the stress/disorder effect – MAP IT. Map a number when it quantifies a BRAIN REGION'S metric (volume, GMV, thickness, activation, connectivity, FA, metabolite) as: patients vs controls, stressed vs non-stressed, a within-patient change, or a correlation with a stress/severity measure. direction = how the region's metric goes in the PATIENT/STRESSED/higher-severity state (decrease/increase/positive_correlation/negative_correlation/null). DO NOT map regression predictors (age, sex, education, medication), task-performance correlations, scanner/coordinate numbers, or protective-factor effects. Output ONLY a JSON array of {brain_region, metric, direction, value, measure_type}; [] if none qualify.

Example 2 (nothing to map -> empty output) –

Sentence: "Reaction times were slower in the patient group (mean 612 vs 548 ms, $p=0.02$), and head motion did not differ between groups ($p=0.41$)."

Output: []

(No brain-region metric is quantified: reaction time is task performance and head motion is a nuisance covariate, so the correct output is the empty array.)

참고문헌

1. Kang B. Large-Scale Scoping Review of Chronic Stress-Induced Brain Changes via LLM-Powered Extraction of 9,585 Studies. Research Square (2026). DOI: 10.21203/rs.3.rs-9884522/v1.
2. Logue MW, van Rooij SJH, Dennis EL, et al. Smaller Hippocampal Volume in Posttraumatic Stress Disorder: A Multisite ENIGMA-PGC Study. *Biol Psychiatry* 2018;83(3):244–253. doi: 10.1016/j.biopsych.2017.09.006.
3. Schmaal L, Veltman DJ, van Erp TGM, et al. Subcortical brain alterations in major depressive disorder: findings from the ENIGMA Major Depressive Disorder working group. *Mol Psychiatry* 2016;21:806–812. doi:10.1038/mp.2015.69.
4. Hedges LV, Olkin I. *Statistical Methods for Meta-Analysis*. Academic Press, 1985.
5. Borenstein M, Hedges LV, Higgins JPT, Rothstein HR. *Introduction to Meta-Analysis*. Wiley, 2009.
6. Murrough JW, Czermak C, Henry S, et al. The effect of early trauma exposure on serotonin type 1B receptor expression revealed by reduced selective radioligand binding. *Arch Gen Psychiatry* 2011;68(9):892–900. PMID:21893657.
7. Burghy CA, Fox ME, Cornejo MD, et al. Experience-driven differences in childhood cortisol predict affect-relevant brain function and coping in adolescent monozygotic twins. *Sci Rep* 2016;6:37081. PMID:27872489.